Segmentazione della copertura del suolo su OpenEarthMap

Relazione sul progetto L115_B_2: PyTorch Lightning e SegFormer

Antonio Buonfiglio · 22 ottobre 2026

1. Obiettivo

Il progetto chiede di addestrare una rete che assegni a ogni pixel di un'immagine aerea o satellitare una delle 9 classi di copertura del suolo di OpenEarthMap (Background, Bareland, Rangeland, Developed space, Road, Tree, Water, Agriculture land, Building) e di valutarla con la IoU multi-classe (indice di Jaccard medio sulle classi, mIoU). Il notebook consegnato contiene il codice completo, gli output dell'esecuzione e una discussione più estesa; questa relazione ne riassume metodo e risultati.

2. Dataset e analisi esplorativa

Il dataset comprende 2.303 immagini di training e 384 di test, RGB, con lato da 406 a 1024 px (per lo più 1024×1024), provenienti da 75 regioni. Tre osservazioni hanno guidato le scelte di progetto:

- **Le 75 regioni sono le stesse nei due split.** Il test misura quindi la prestazione su immagini nuove di regioni già viste. Per questo la validation è un 20% casuale di `train.txt` (seed 42), e il test resta intatto fino alla valutazione finale.
- **Le classi sono fortemente sbilanciate.** Background copre lo 0,7% dei pixel, Bareland l'1,8% e Water il 3,2%, contro il 17–21% di Rangeland, Developed space, Tree e Building. Questo motiva una cross-entropy pesata (pesi proporzionali a 1/√frequenza, normalizzati a media 1) e la Dice loss.
- **Background indica aree non etichettate.** Oltre alla mIoU su 9 classi richiesta, riportiamo quindi la mIoU sulle 8 classi di copertura del suolo, la convenzione del benchmark OpenEarthMap.

3. Metodo

- **Dati.** `OEMDataset` legge i GeoTIFF con rasterio. `OEMDataModule` applica in training un crop casuale 224×224 con normalizzazione ImageNet e, quando attiva, un'augmentation: flip, rotazioni di 90° e una leggera variazione di colore. Poiché un crop copre circa il 5% dell'immagine, ogni epoca estrae 4 crop diversi per immagine (58 step con batch 128).
- **Valutazione.** Validation e test usano le immagini intere, portate a 1024×1024 con padding. I pixel di padding hanno etichetta 255 e sono esclusi da loss e metriche. Tutte le run condividono seed, split, protocollo e criterio di checkpoint (miglior mIoU di validation); il test viene eseguito una sola volta, sul checkpoint migliore.
- **Modello.** SegFormer (`segmentation_models_pytorch`) con encoder Mix Transformer pre-addestrato su ImageNet, nelle versioni mit_b0 (3,7 M parametri) e mit_b2 (~25 M). L'encoder non usa positional embedding fissi, quindi un modello addestrato su crop 224 può predire direttamente su immagini 1024.
- **Ottimizzazione.** AdamW in precisione mista a 16 bit. Nelle run migliorate il learning rate è stato scelto con il LR finder di Lightning: la loss ha il minimo a ~$3 \cdot 10^{-3}$, e scegliamo $5 \cdot 10^{-4}$, circa un ordine di grandezza sotto. È affiancato da un warm-up lineare (5% degli step) e da un decadimento coseno.

Gli esperimenti sono stati eseguiti su una GPU RTX 3080 Laptop (16 GB). Il notebook rileva l'ambiente ed è predisposto anche per Google Colab, come il setup originale.

4. Esperimenti

La baseline E0 implementa le specifiche dei TODO con lo stesso budget di training dei valori predefiniti (~1.450 step). Ogni run successiva aggiunge **una** modifica alla precedente, così da attribuire a ciascuna il proprio effetto (ablation cumulativa).

Run	Modifica rispetto alla run precedente	Step	mIoU val	mIoU test (9 cl.)	mIoU test (8 cl.)	Δ test vs E0	Tempo
E0	Baseline secondo i TODO: mit_b0, cross-entropy, nessuna augmentation, lr costante 10^{-4}	1.450	0,625	0,628	0,588	–	17 min
E1	+ augmentation (flip, rotazioni di 90°, colour jitter)	1.450	0,613	0,625	0,586	-0,004	18 min
E2	+ cross-entropy pesata per classe + Dice loss	1.450	0,621	0,617	0,574	-0,011	19 min
E3	+ lr $5{\cdot}10^{-4}$ con warm-up e coseno, training 2,4× più lungo	3.480	0,656	0,660	0,622	+0,032	45 min
E4	**+ encoder mit_b2 (batch 64 × 2 di accumulo del gradiente)**	**3.480**	**0,685**	**0,688**	**0,653**	**+0,059**	**78 min**

Tabella 1. Risultati dell'ablation. mIoU val: miglior valore sul validation set (9 classi); mIoU test: checkpoint migliore, valutato su immagini intere; 8 cl.: senza Background. Tempo: durata del training sulla RTX 3080.

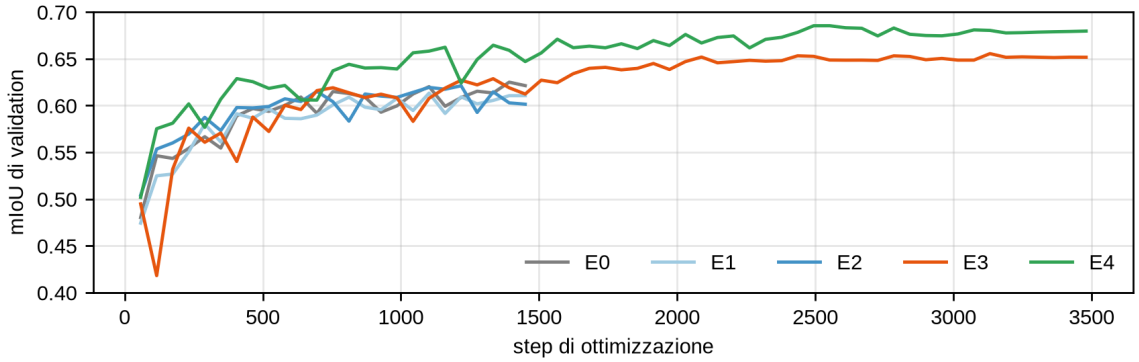


Figura 1. mIoU di validation durante il training. E0–E2 (1.450 step) stanno ancora migliorando quando il training si ferma; E3 ed E4 (3.480 step) si stabilizzano nella seconda metà del decadimento coseno.

5. Analisi dei risultati

Cosa ha funzionato. Il guadagno maggiore viene dall'allenare abbastanza a lungo con un learning rate adeguato: da E2 a E3 la mIoU di test sale di 0,043, e di 0,032 rispetto alla baseline. La baseline era quindi limitata dal budget, non dall'architettura. L'encoder più grande (E3 → E4) aggiunge 0,027 e migliora tutte le classi, soprattutto Bareland (+0,045) e Road (+0,041), al prezzo di un training 1,7 volte più lungo.

Cosa non ha funzionato al budget breve. Augmentation (E1) e loss pesata CE + Dice (E2) spostano la mIoU di test di meno di ±0,011 rispetto alla baseline, e i pesi di classe non hanno migliorato le classi rare (Water: 0,690 → 0,658). Con 1.450 step il modello è ancora sotto-adattato: tecniche che regolarizzano o rendono l'obiettivo più difficile non possono dare frutti. Inoltre ogni configurazione è stata addestrata una sola volta, e la mIoU di validation oscilla di circa ±0,02 da un'epoca all'altra: differenze così piccole non sono significative. E3 ed E4 mantengono entrambe le tecniche, ma manca la run di controllo «training lungo senza di esse», quindi il loro contributo al budget lungo non è isolato.

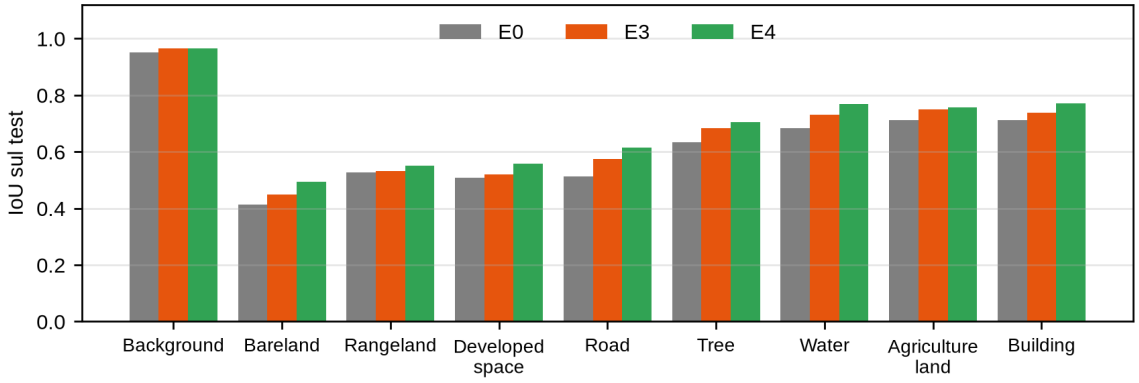


Figura 2. IoU per classe sul test per la baseline (E0), E3 ed E4.

Dove sbaglia il modello. Background è la classe più facile (IoU 0,97) pur coprendo meno dell'1% dei pixel, e Water (2,3%) raggiunge 0,77: la rarità da sola non rende difficile una classe, lo fa l'ambiguità visiva. Le classi più difficili sono Bareland (0,49), Rangeland (0,55) e Developed space (0,56). La matrice di confusione di E4 mostra che il 31% dei pixel Bareland è predetto come Developed space, il 18% dei pixel Road come Developed space, e che Rangeland e Tree si confondono in entrambe le direzioni (14% e 11%). Sono coppie simili viste dall'alto (suolo nudo e spazi aperti non pavimentati, prato e arbusti o chiome), in cui il confine dipende dal contesto e dalle convenzioni di annotazione.

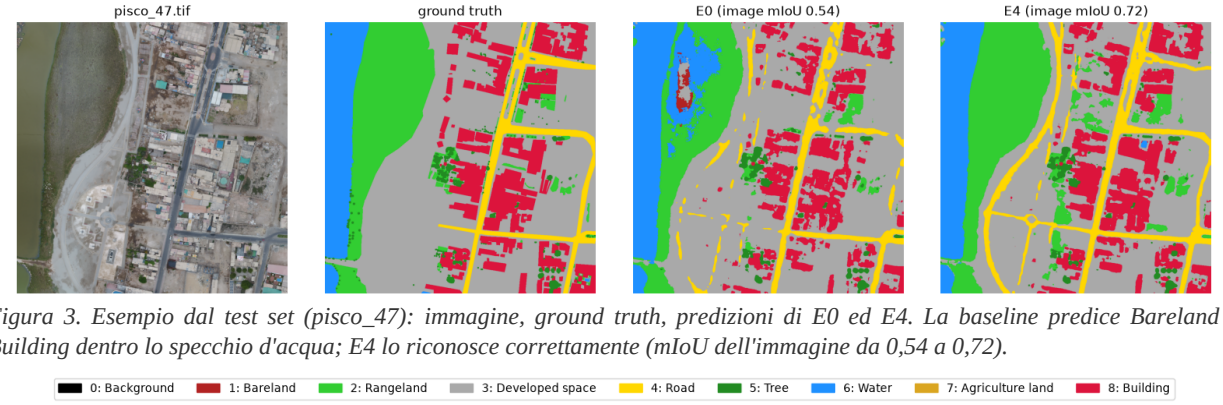


Figura 3. Esempio dal test set (pisco_47): immagine, ground truth, predizioni di E0 ed E4. La baseline predice Bareland e Building dentro lo specchio d'acqua; E4 lo riconosce correttamente (mIoU dell'immagine da 0,54 a 0,72).

Affidabilità della validation. In ogni run la differenza tra miglior mIoU di validation e mIoU di test è al massimo 0,011, a conferma che lo split casuale di `train.txt` è un buon criterio di selezione del modello.

6. Conclusioni e limiti

La baseline richiesta dai TODO (0,628 di mIoU di test) era limitata soprattutto dal budget di training. Un learning rate scelto con il LR finder, uno scheduler warm-up + coseno e un training più lungo la portano a 0,660; un encoder più grande a **0,688** (0,653 sulle 8 classi senza Background), +0,059 rispetto alla baseline. Gli errori residui si concentrano tra classi semanticamente vicine più che sulle classi rare. Limiti dello studio:

- **Un solo seed per configurazione:** differenze sotto ~0,02 di mIoU non vanno considerate significative.
- **Ablation cumulativa:** E3 cambia insieme learning rate, scheduler e budget, e l'effetto di augmentation e loss al budget lungo non è separato.
- **Scala diversa tra training e test:** il modello è addestrato su crop 224×224 e valutato su immagini fino a 1024×1024. Crop più grandi darebbero più contesto, ma mit_b2 a 512×512 con batch 32 non entra in 16 GB di memoria GPU.
- **Valutazione in-distribution:** validation e test provengono dalle stesse 75 regioni, quindi i risultati non misurano la generalizzazione a città mai viste.

Sviluppi naturali: più seed per configurazione, una valutazione su regioni escluse dal training, test-time augmentation (flip) e crop più grandi con accumulo del gradiente.